ITBA
Instituto Tecnológico de Buenos Aires

COMPETENCIA KAGGLE

Federico Kaplun

Score obtenido

Submission and Description	Public Score
 **predicciones_finales (1).csv** Complete (after deadline) · 2h ago	**0.69529**

- **01:** Introducción
- **02:** Tratamiento del DataSet
- **03:** Selección de modelos
- **04:** Conclusiones

La base contiene información sobre alojamientos publicados en Airbnb en la ciudad de Amsterdam.

La base de entrenamiento cuenta con 4.928 registros con 67 variables.
La base de testeo cuenta con 1.233 registros, con 66 variables. La variable a predecir es *review_scores_rating*.

Preparación de la base:

- Se **eliminaron columnas nulas** y que no aportaban (‘id', 'host_id', 'host_name', ‘license’)
- Se confirma que la base **no contiene duplicados**
- Se normalizan columnas **numéricas no preparadas** (Columnas con porcentajes, dinero, etc.)
- Se normalizan las **columnas de fecha**
- Se formatean las **columnas booleanas**
- Se establecen **criterios útiles** para las **columnas de texto**

Para las variables *'name', 'description', 'neighborhood_overview', 'host_about', 'amenities', 'host_verifications'*:

Primero se establecen **dos supuestos:**

- Una buena review juzga la veracidad de lo ofertado
- Entre mas descripcion hay, mas cercana a la realidad será la expectativa

Se cambió el contenido de las columnas por un **conteo de las palabras que ellas contienen.**

```
import re

text_columns = ['name', 'description', 'neighborhood_overview', 'host_about', 'amenities', 'host_verifications']

for column in text_columns:
    df[column] = df[column].apply(lambda x: len(re.findall(r'\b\w+\b', x.lower())) if isinstance(x, str) else 0)
```

Más criterios para variables de texto:

- Para las variables categoricas ('room_type', 'property_type', 'neighbourhood_cleansed', 'host_neighbourhood', 'host_location', 'host_response_time') se realizo un *encoding*, cambiando cada categoría por un número entero
- Para las fechas ('host_since', 'calendar_last_scraped', 'first_review', 'last_review'), se estableció como base (1) la fecha más antigua, y el resto son números enteros partiendo desde ahí

	host_since	calendar_last_scraped	first_review	last_review
0	795	4502	4350	4354
1	1879	4502	4249	4409
2	2911	4502	4298	4308
3	2116	4502	4258	4272
4	4074	4502	4333	4468

Entrenamiento de modelos:

Luego de todos estos cambios, obtenemos un DataFrame de **xxx** variables, aun con **xxx** registros.

Para entrenar a los modelos, se realizó una partición del dataset de entrenamiento de **80-20.**

Se utilizó el método **Random Search,** ampliando los parámetros como se vio necesario

Modelos utilizados:

- XGBRegressor
- Linear Regression
- Extra Trees Regressor
- **Random Forest Regressor**
- CatBoost Regressor
- LGBMRegressor
- Decision Tree Regressor
- AdaBoost Regressor
- SVR (Support Vector Regression)

Modelo elegido: Random Forest Regressor

De todos los modelos probados, consistentemente devolvió el r2 más alto. Para mejorarlo aún más, se realizó un análisis de *feature importance*, lo que reveló que variables fueron las más utilizadas para el modelo:

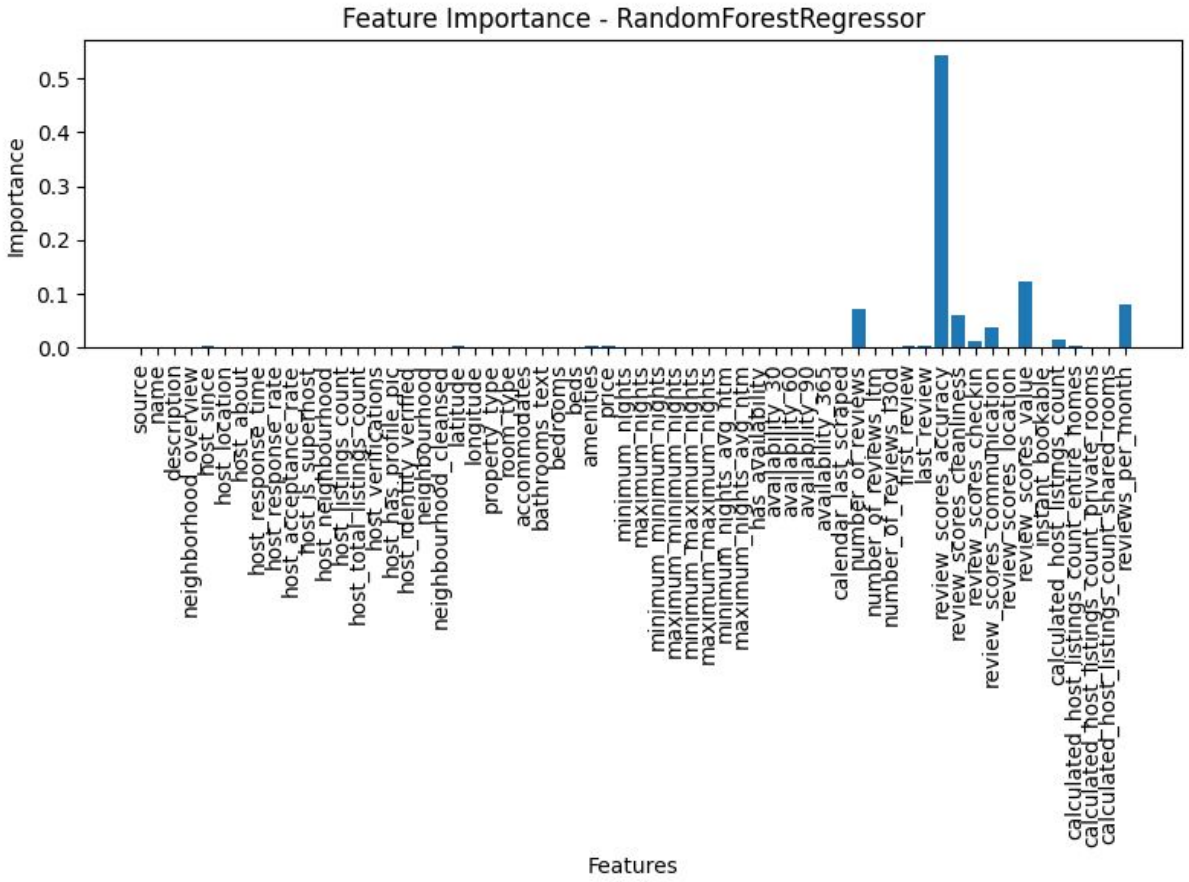

Selección de modelo:

Aunque el *feature analysis* no haya dado frutos (mejor r2 sin *feature analysis* **0.8182**, mejor r2 **con** *feature analysis*, **0.7603**), el **Random Forest Regression sigue siendo el mejor modelo.**

Random Forest Regression

Se crean múltiples árboles de decisión, y cada uno realiza una predicción individual. Luego las predicciones se promedian para obtener la predicción final

Ventajas:

- Precisión
- Escalabilidad
- Robustez

Mejores hiperparametros:

```
model = RandomForestRegressor(bootstrap=True, ccp_alpha=0.0, criterion='squared_error',
                              max_depth=None, max_features=1.0, max_leaf_nodes=None,
                              max_samples=None, min_impurity_decrease=0.0, min_samples_leaf=1,
                              min_samples_split=2, min_weight_fraction_leaf=0.0, n_estimators=100,
                              n_jobs=None, oob_score=False, random_state=None, verbose=0,
                              warm_start=False)
```

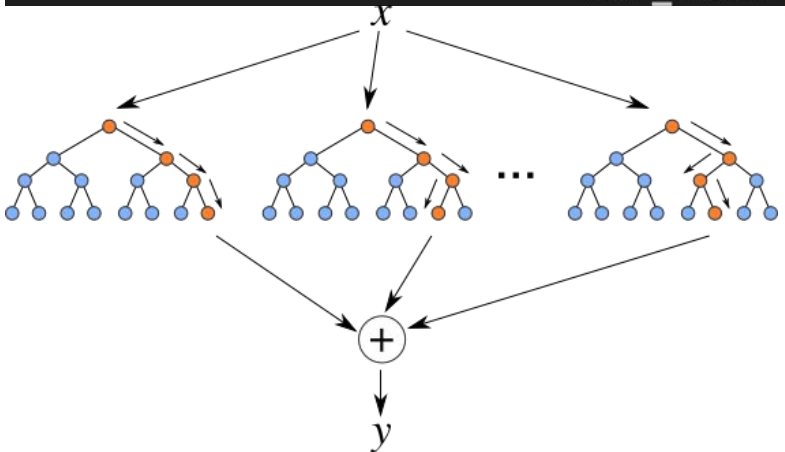

ITBA
Instituto Tecnológicc
de Buenos Aires

¡Gracias!